



Pairwise Wilcoxon Signed-Rank Tests (Bonferroni Correction)

Comparison	p-value	Significant (p<0.05)
Claude 3.7 Sonnet vs Llama 3.1 8B	0.0000	✓
Claude 3.7 Sonnet vs Llama 3.3 70B	0.0021	✓
Claude 3.7 Sonnet vs Ministral 8B	1.0000	
Claude 3.7 Sonnet vs Qwen 2.5 72B	1.0000	
Llama 3.1 8B vs Llama 3.3 70B	0.0048	✓
Llama 3.1 8B vs Ministral 8B	0.0000	✓
Llama 3.1 8B vs Qwen 2.5 72B	0.0000	✓
Llama 3.3 70B vs Ministral 8B	0.0010	✓
Llama 3.3 70B vs Qwen 2.5 72B	0.0071	✓
Ministral 8B vs Qwen 2.5 72B	1.0000	