



Pairwise Wilcoxon Signed-Rank Tests

Comparison	Statistic	p-value	Significant (p<0.05)
Claude 3.7 Sonnet vs Llama 3.1 8B	0.0000	0.0000	✓
Claude 3.7 Sonnet vs Llama 3.3 70B	0.0000	0.0000	✓ ·
Claude 3.7 Sonnet vs Ministral 8B	1.0000	0.0000	✓ ·
Claude 3.7 Sonnet vs Qwen 2.5 72B	19.0000	0.0006	✓ ·
Llama 3.1 8B vs Llama 3.3 70B	10.0000	0.0001	✓
Llama 3.1 8B vs Ministral 8B	5.0000	0.0000	✓
Llama 3.1 8B vs Qwen 2.5 72B	0.0000	0.0000	✓
Llama 3.3 70B vs Ministral 8B	60.0000	0.0973	
Llama 3.3 70B vs Qwen 2.5 72B	2.0000	0.0000	· /
Ministral 8B vs Qwen 2.5 72B	33.0000	0.0056	✓