

Model Pair	Nemenyi p-value	Nemenyi Sig (p<0.05)	Wilcoxon p-value	Wilcoxon Sig (p<0.05)
Claude 3.7 Sonnet vs Llama 3.1 8B	0.0000	✓	0.0000	✓
Claude 3.7 Sonnet vs Llama 3.3 70B	0.0000	✓	0.0000	✓
Claude 3.7 Sonnet vs Ministral 8B	0.0009	✓	0.0000	✓
Claude 3.7 Sonnet vs Qwen 2.5 72B	0.4973		0.0059	✓
Llama 3.1 8B vs Llama 3.3 70B	0.1796		0.0008	✓
Llama 3.1 8B vs Ministral 8B	0.0120	✓	0.0002	✓
Llama 3.1 8B vs Qwen 2.5 72B	0.0000	✓	0.0000	✓
Llama 3.3 70B vs Ministral 8B	0.8555		0.9731	
Llama 3.3 70B vs Qwen 2.5 72B	0.0086	✓	0.0001	✓
Ministral 8B vs Qwen 2.5 72B	0.1448		0.0558	